


① Eingabeschicht verborgene Schichten Ausgangsschicht



1
Eingabe $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$

2

→ Aktivierung der ersten Schicht:


$$y = \sigma(\hat{y})$$

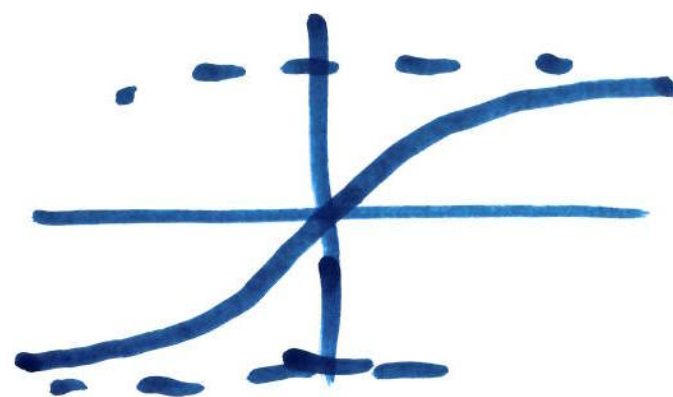
$$\hat{y} = Vx + b$$

$$\begin{pmatrix} \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \end{pmatrix}$$

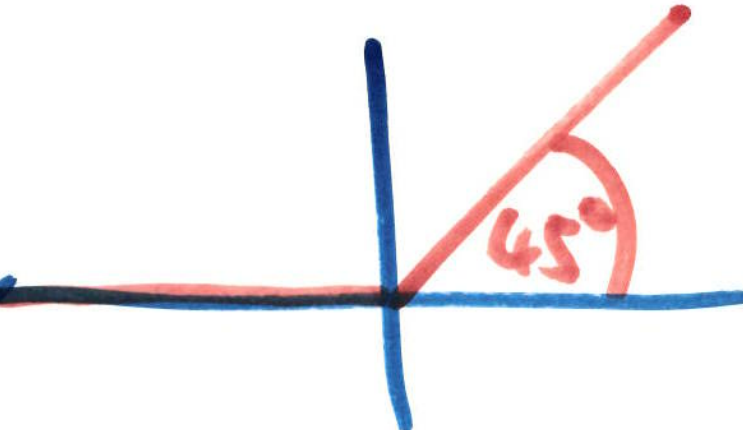
$$\begin{pmatrix} b_1 \\ \vdots \\ b_n \end{pmatrix}$$



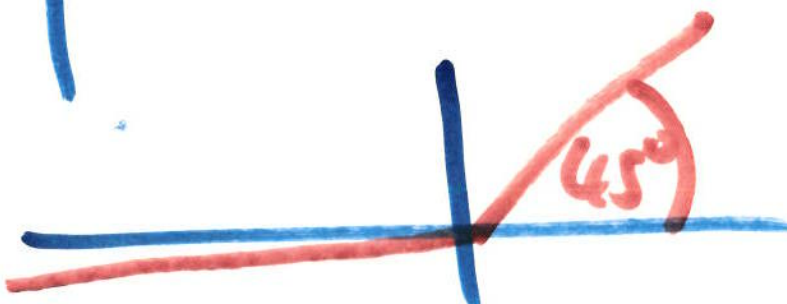
① $\sigma(x) = \frac{e^x}{1+e^x}$? ~~plot~~ ~~...~~ 

② $\tanh(x)$ 

③ RELU
Rectified Linear



④



(26)

$$\hat{y}_n = V_{n1}x_n + V_{n2}x_n + \dots + V_{ni}x_i + b_n$$

$$y_n = \sigma(\hat{y}_n)$$

Das Wunder des Lernens

Re
3

Ziel: Finde Familie und Bias,
s.d. die Abbildung $x \mapsto z$ ← Ausgabevektor
möglichst stark einer idealen Abb.
 $x \mapsto \text{das richtige } z$

ähnelt.

Realist. Ziel:

(4)

Nimm Trainingsdaten

$x^{(1)}, \dots, x^{(N)}$

$N = 80000$

mit bekannten gewünschten
Ausgabeaktivierungen

$\bar{z}^{(1)}, \dots, \bar{z}^{(N)}$.

Definiere Kostenfunktion

⑤

$$K(\dots) := \sum_{i=1}^N \| \hat{z}^{(i)} - \bar{z}^{(i)} \|^2$$

K hängt ab
von allen Verbindungen
gewichteten und
Biases

was das NN
als Ausgabe
produziert

← Länge
des Vektors
 $\sqrt{v_1^2 + \dots + v_n^2}$
← Sollergebnis
für Trainingsdaten;
;

Lernen durch Gradientenabstieg:

⑥

① Beginne mit willkürlichen Gewichten & Bias.

② Berechne ∇K .

$$A = \begin{pmatrix} \vdots \end{pmatrix}$$

③ Neues $A :=$

$$\text{altes } A - \eta \cdot \nabla K$$

④ Made weiter bis ②.

Schrittweite
Lernrate,
z.B. 0.01


$$f: \mathbb{R}^n \longrightarrow \mathbb{R}$$


$$(\nabla f)(p) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(p) \\ \vdots \\ \frac{\partial f}{\partial x_n}(p) \end{pmatrix}$$

$$f(x, y) = (x^2 - \sin(y)) \cdot x$$

$$(\nabla f)(x, y) = \begin{pmatrix} 2x - \sin(y) \\ -x \cos(y) \end{pmatrix}$$

∇f zeigt ⑦
in Richtung des
steilsten Anstiegs





Wie berechnet man ∇K ? „nahe K“

⑨


~~1~~ $\nabla K \approx \frac{K(A + \text{ein bisschen}) - K(A)}{\text{„ein bisschen“}}$

↑ produziert
in der Praxis
Zufallswerte

② ∇K per Hand berechnen

~~3~~ ∇K durch „symb. Diff.“ bestimmen

④ ∇K durch „automal. Diff.“ bestimmen



10

$$\hat{y} = Vx + b$$

$$\hat{z} = Wy + c$$

$$y = \sigma(\hat{y})$$

$$z = \sigma(\hat{z})$$

$$K = \sum \dots$$

qs: ∇K
gradients: $\nabla_{v_1} K, \dots, \nabla_{b_1} K, \dots$

Def.: $\delta_k := \frac{\partial K}{\partial \hat{z}_k}, \gamma_j := \frac{\partial K}{\partial \hat{y}_j}$

[1] $\delta_k = \frac{\partial K}{\partial z_k} \sigma'(\hat{z}_k)$

[2] $\gamma_j = (W^T \delta)_j \cdot \sigma'(\hat{y}_j)$

[3] $\frac{\partial K}{\partial c_k} = \delta_k, \quad \frac{\partial K}{\partial b_j} = \gamma_j$

[4] $\frac{\partial K}{\partial w_{kj}} = \gamma_j \delta_k, \quad \frac{\partial K}{\partial v_{ji}} = x_i \gamma_j$

11a

Zu 11:

$$\delta_k = \frac{\partial K}{\partial \hat{z}_k} = \frac{\partial K}{\partial z_k} \cdot \frac{\partial z_k}{\partial \hat{z}_k}$$

Kettenregel

$$= \frac{\partial K}{\partial z_k} \cdot \sigma'(\hat{z}_k)$$


$$z_k = \sigma(\hat{z}_k)$$

$$y(x) \rightsquigarrow y'(x) = \frac{\partial y}{\partial x}$$

116

Convolutional NN

12



13

